지난 포스팅에서는 TRPO 논문의 스토리에 대해서 심도 있게 다뤄보았다. TRPO는 일반적인 정책에 대해서 정책의 monotonic improvement를 보장할 수 있는 방법을 이론과 함께 제시하였다. 하지만, 이론이 복잡할수록 구현은 어려운 법이다. 유명 강화학습 라이브러리에서도 TRPO의 구현체가 없는 것을 보면 TRPO는 구현이 어렵다는 것을 간접적으로 알 수 있다. 내 생각에 TRPO에서 중요한 부분은 현재 정책과 "가까운 정책들 중에서" performance measure를 최적화하는 정책을 찾는 것이다. 이는 performance measure를 최적화하는 방향을 먼저 찾고, 그 방향으로 정책을 아주 조금만 업데이트하면 어느 정도 위의 사항을 달성할 수 있다. PPO는 TRPO의 업데이트 크기를 clip하여 정책을 조금씩만 업데이트 하는 방법이라고 요약할 수 있다.

- 제목: Proximal Policy Optimization Algorithms
- 저자: John Schulman, Filip Wolski, Prafulla Dhariwal, Alec Radford, Oleg Klimov, ***Open AI***
- 연도: 2017
- 링크: https://arxiv.org/abs/1707.06347

TRPO의 목적함수

TRPO는 업데이트 전 정책 $\pi_{\theta_{\text{old}}}$와 업데이트 후 정책 π_θ의 KL divergence에 대해 제약 (constraint)을 걸어 다음 surrogate objective를 최대화를 했다.

$$\underset{\theta}{\text{maximize}} \hat{\mathbb{E}}_t \left[\frac{\pi_\theta\left(a_t|s_t\right)}{\pi_{\theta_{\text{old}}}\left(a_t|s_t\right)} \hat{A}_t \right], \qquad (1)$$

$$\text{subject to} \quad \hat{\mathbb{E}}_t \left[\text{KL}[\pi_{\theta_{\text{old}}}\left(\cdot|s_t\right), \pi_\theta\left(a_t|s_t\right)] \right] \leq \delta. \qquad (2)$$

해석하자면,

- 정책은 주어진 상태에 대한 행동들의 확률분포이기 때문에 두 정책 사이의 KL divergence를 계산할 수 있다.
- 업데이트 전, 후 정책의 KL divergence를 δ 이하로 유지하면서 식 (1)의 surrogate objective를 최대화.
- TRPO에서는 식 $(1), (2)$의 constraint optimization 대신 아래의 (3)을 최대화하는 방법도 제안했지만, β 값을 하나로 정하는 것이 매우 어렵다고 한다. β를 환경에 따라 지정해줘야할 뿐만 아니라, 사실 학습 도중에도 adaptive하게 바꿔줘야할 필요가 있었다.

$$\underset{\theta}{\text{maximize}} \hat{\mathbb{E}}_t \left[\frac{\pi_\theta\left(a_t|s_t\right)}{\pi_{\theta_{\text{old}}}\left(a_t|s_t\right)} \hat{A}_t - \beta \text{KL}[\pi_{\theta_{\text{old}}}\left(\cdot|s_t\right), \pi_\theta\left(a_t|s_t\right)] \right]. \qquad (3)$$

논문의 해결책

Clipped Surrogate Objective

- KL divergence를 이용하여 업데이트의 크기를 제한하지 않고, 애초에 업데이트 대상인 $\frac{\pi_\theta(a_t|s_t)}{\pi_{\theta_{\text{old}}}(a_t|s_t)}\hat{A}_t$의 크기를 clipping하여 제한.
- 표기의 편의를 위해 $r_t\left(\theta\right)=\frac{\pi_\theta(a_t|s_t)}{\pi_{\theta_{\text{old}}}(a_t|s_t)}$ 라 하자. (진작에 할껄 ,,,)

$$L^{\text{CLIP}}\left(\theta\right)=\hat{\mathbb{E}}_t\left[\min\left(r_t\left(\theta\right)\hat{A}_t,\text{clip}(r_t\left(\theta\right),1-\epsilon,1+\epsilon)\hat{A}_t\right)\right], \qquad (4)$$

where

$$\text{clip}(x,\text{low},\text{high})=\begin{cases}\text{low} & \text{if } x<\text{low}\\ x & \text{if low}\le x<\text{high}\\ \text{high} & \text{if } x\ge\text{high}\end{cases}$$

- 우선 $\theta=\theta_{\text{old}}$ 일 때 $r_t\left(\theta\right)=1$ 에서 업데이트를 시작한다.
- 만약 $\hat{A}_t>0$ 라면, 상태 s_t에서 행동 a_t를 취할 확률을 높여주는 방향으로 policy를 업데이트하게 된다. 따라서 $r_t\left(\theta\right)$이 1보다 커지게 된다. 이때, clip은 $r_t\left(\theta\right)$이 $1+\epsilon$ 까지만 커지도록 만들어준다.
- 반대로 만약 $\hat{A}_t<0$ 라면, 상태 s_t에서 행동 a_t를 취할 확률을 낮춰주는 방향으로 policy를 업데이트한다. 즉, $r_t\left(\theta\right)$이 1보다 작아지게 된다. 이때, clip은 $r_t\left(\theta\right)$이 $1-\epsilon$ 까지만 작아지게 만들어준다.

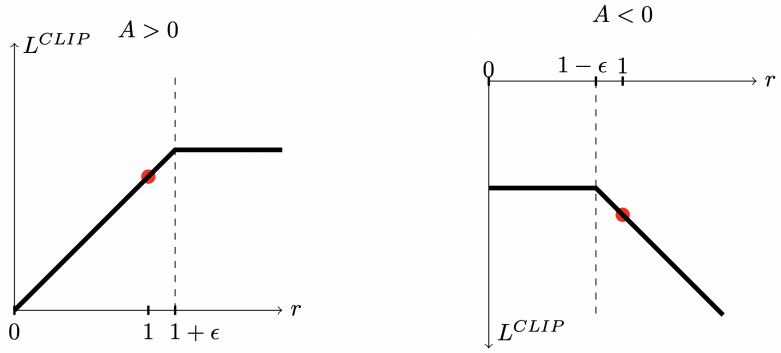

Adpative KL Penalty Coefficient

Clipped surrogate objective 방법 대신 식 (3)의 β를 policy가 업데이트 정도에 따라 adaptive하게 바꿔주는 방법인데, 굳이 정리할 필요까지는 없는 듯 ..?

전체 목적 함수

우선 Advantage에 대한 추정량 (estimator)는 다음과 같다.

$$\hat{A}_t = \delta_t + (\gamma\lambda)\delta_{t+1} + \cdots + (\gamma\lambda)^{T-t+1}\delta_{T-1}, \qquad (5)$$

$$\text{where} \quad \delta_t = r_t + \gamma V(s_{t+1}) - V(s_t). \qquad (6)$$

$\lambda = 1$일 때를 살펴보면 조금 와닿는다.

$$\hat{A}_t = -V(s_t) + r_t + \gamma r_{t+1} + \cdots + \gamma^{T-t+1} r_{T-1} + \gamma^{T-t} V(S_T)$$

우리가 아는 advantage $A_t = Q(s_t, a_t) - V(s_t)$ 과 식 (6)을 비교해보면 $-V(s_t)$는 동일하게 갖고 있으며, 나머지 텀 $r_t + \gamma r_{t+1} + \cdots + \gamma^{T-t+1} r_{T-1} + \gamma^{T-t} V(S_T)$ 는 $Q(s_t, a_t)$를 추정량이다. 이 논문에서 제안하는 전체 목적 함수는 다음과 같다.

$$L_t^{\mathrm{CLIP+VF+S}}(\theta) = \hat{\mathbb{E}}_t \left[L_t^{\mathrm{CLIP}}(\theta) - c_1 L_t^{\mathrm{VF}}(\theta) + c_2 S[\pi_\theta](s_t) \right], \qquad (7)$$

where $L_t^{\mathrm{VF}}(\theta) = \left(V_\theta(s_t) - V_t^{\mathrm{targ}} \right)^2$ 으로 가치 함수 approximator를 훈련시키기 위한 텀이다. $S[\pi_\theta](s_t)$은 entropy bonus으로서 exploration을 하게 만들어주는 텀이다. c_1, c_2는 각 텀에 대한 가중치이다.

Algorithm

- 요약: N개의 policy가 각각 병렬적으로 환경과 T번 상호작용하여 NT개의 경험 데이터 획득하고, 이 경험 데이터들을 사용하여 목적 함수 최적화

Algorithm 1 PPO, Actor-Critic Style

for iteration=$1, 2, \ldots$ **do**
  for actor=$1, 2, \ldots, N$ **do**
    Run policy $\pi_{\theta_{\text{old}}}$ in environment for T timesteps
    Compute advantage estimates $\hat{A}_1, \ldots, \hat{A}_T$
  end for
  Optimize surrogate L wrt θ, with K epochs and minibatch size $M \leq NT$
  $\theta_{\text{old}} \leftarrow \theta$
end for

Experiment

Experimental setting

- HalfCheetah, Hopper, InvertedDoublePendulum, InvertedPendulum, Reacher, Swimmer, Walker2d, all "-v1", OpenAI Gym.
- Policy network: a MLP with two hidden layers of 64 units, tanh nonlinearities, outputting the mean of a Gaussian distribution, with variable standard deviations.
- No parameter sharing between policy and value function
- No entropy bonus
- Train for 1 million timesteps
- $\gamma = 0.99, \lambda = 0.95$

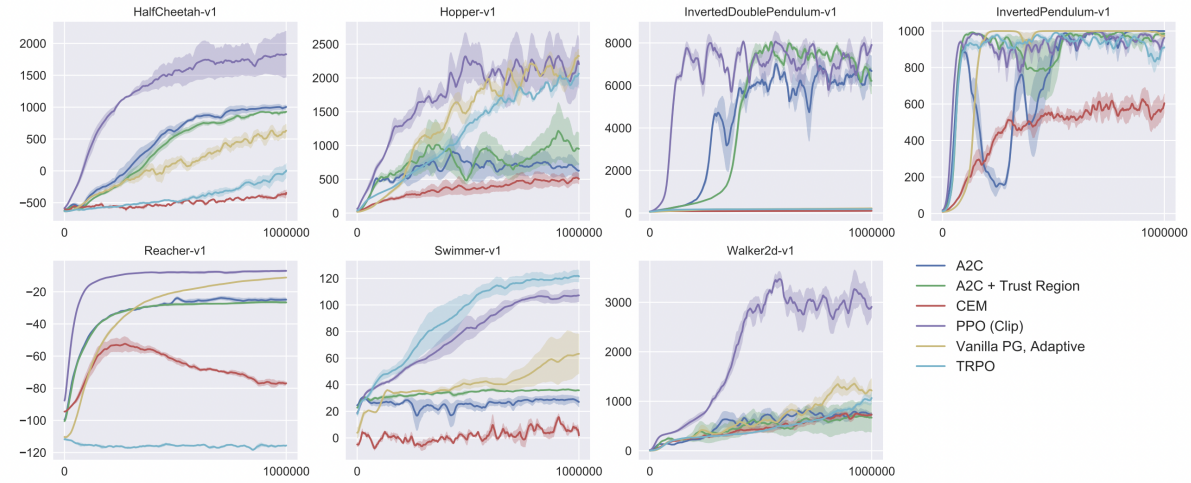

Figure 3: Comparison of several algorithms on several MuJoCo environments, training for one million timesteps.

참고 문헌

Schulman, J., Wolski, F., Dhariwal, P., Radford, A., & Klimov, O. (2017). Proximal Policy Optimization Algorithms. arXiv. https://doi.org/10.48550/arXiv.1707.06347